



中国认可
检测
TESTING
CNAS L8372

报告编号: STS425323



软件测试报告

项目名称 大模型四维并行分布式训练支撑系统项目

软件名称 大模型四维并行分布式训练支撑系统

版本号 V1.0

送测单位 浦江国家实验室

送测日期 二〇二五年十二月十九日

测试类型 软件验收测试

报告日期 二〇二六年二月二十八日

上海浦东软件平台有限公司

GPipe-V 模式/PipeDream-V 模式相较于 GPipe 模式/PipeDream 模式的吞吐量加速比> 0% 且运行日志无报错, 即在长流水线并行训练场景下具有可用性与优化能力”。

4.2.3. 三维并行融合调度训练系统测试 (64GPU)

(1) 性能效率要求

检测该软件三维并行“计算-通信同步”调度算法模式对比三维并行“基线 Megatron-LM”模式下的模型训练吞吐量提升百分比达到或超过 30%, 在三维并行“计算-通信同步”调度算法模式下输出“schedule.json”文件, 显示时间重叠 (Overlap) 参数。

注⁴: 在本次测试中, 输出“schedule.json”文件中包含 overlap_params, 即判定为显示时间重叠 (Overlap) 参数。

(2) 测试设计

通过 SSH V13 输入命令, 分别在三维并行“计算-通信同步”调度算法模式下、三维并行“基线 Megatron-LM”模式下执行 18B 参数量 GPT-3 模型训练, 查看日志输出的模型训练吞吐量, 计算出模型训练吞吐量加速比, 查看三维并行“计算-通信同步”调度算法模式下输出“schedule.json”文件中显示的时间重叠 (Overlap) 参数。

计算公式如下:

模型训练吞吐量加速比=(三维并行“计算-通信同步”调度算法模式模型训练吞吐量—三维并行“基线 Megatron-LM”模式下的模型训练吞吐量)÷三维并行“基线 Megatron-LM”模式下的模型训练吞吐量×100%。

(3) 测试步骤

- 1) 部署 8 台英伟达服务器 (GPU: 8 卡英伟达 2080 Ti, IP 地址: 172.31.43.176, 172.31.43.10, 172.31.0.55, 172.31.10.100, 172.31.16.25, 172.31.32.201, 172.31.48.11, 172.31.64.99) 环境;

- 2) 通过 SSH V13 分别输入 “bash megatron.sh 18B 8”和“bash overlap.sh 18B 8”命令, 分别在三维并行“计算-通信同步”调度算法模式和三维并行“基线 Megatron-LM”模式下执行 105 步的 18B 参数量 GPT-3 模型训练;
- 3) 执行完毕后, 查看在三维并行“计算-通信同步”调度算法模式下输出“schedule.json”文件;
- 4) 执行完毕后, 查看日志并记录在三维并行“计算-通信同步”调度算法模式下和三维并行“基线 Megatron-LM”模式下模型训练吞吐量, 在三维并行“计算-通信同步”调度算法模式下输出“schedule.json”文件中显示时间重叠 (Overlap) 参数;
- 5) 依据计算公式计算出模型训练吞吐量加速比。

(4) 测试结果

测试项	测试结果
三维并行“计算-通信同步”调度算法模式模型训练吞吐量 (tokens/s)	24351.6
三维并行“基线 Megatron-LM”模式下的模型训练吞吐量 (tokens/s)	18617.2
模型训练吞吐量加速比 (%)	30.80
输出文件“schedule.json”中显示时间重叠 (Overlap) 参数	“schedule.json”文件中包含“overlap_params”

经检测,在本次 8 台英伟达服务器(GPU:8 卡英伟达 2080 Ti, IP 地址:172.31.43.176, 172.31.43.10, 172.31.0.55, 172.31.10.100, 172.31.16.25, 172.31.32.201, 172.31.48.11, 172.31.64.99) 测试环境中, 通过 SSH V13 输入命令, 在三维并行“计算-通信同步”调度算法模式下、三维并行“基线 Megatron-LM”模式下执行 18B 参数量 GPT-3 模型训练, 执行完毕查看输出文件“schedule.json”文件中显示时间重叠 (Overlap) 参数为“overlap_params”, 三维并行“计算-通信同步”调度算法模式对比三维并行“基

线 Megatron-LM”模式下的模型训练吞吐量提升百分比为 30.80%，模型训练吞吐量加速比超过 30%，满足测试项“三维并行‘计算-通信同步’调度算法模式对比三维并行‘基线 Megatron-LM’模式下的模型训练吞吐量提升百分比达到或超过 30%，在三维并行‘计算-通信同步’调度算法模式下输出‘schedule.json’文件包含‘overlap_params’，显示时间重叠（Overlap）参数”。

4.2.4. 三维并行融合调度训练系统测试（128GPU）

（1）性能效率要求

在三维并行“计算-通信同步”调度算法模式下比三维并行“基线 Megatron-LM”模式下的模型训练吞吐量提升百分比达到或超过 30%。

（2）测试设计

通过 SSH V13 输入命令，分别在三维并行“计算-通信同步”调度算法模式下、三维并行“基线 Megatron-LM”模式下执行 39B 参数量 GPT-3 模型训练，查看日志输出的模型训练吞吐量，计算出模型训练吞吐量提升百分比，计算结果四舍五入取 2 位小数。

计算公式如下：

模型训练吞吐量加速比 = (三维并行“计算-通信同步”调度算法模式模型训练吞吐量 - 三维并行“基线 Megatron-LM”模式下的模型训练吞吐量) ÷ 三维并行“基线 Megatron-LM”模式下的模型训练吞吐量 × 100%。

（3）测试步骤

- 1) 部署 16 台英伟达服务器（GPU：8 卡英伟达 2080 Ti，IP 地址：172.31.43.176，172.31.43.10，172.31.0.55，172.31.10.100，172.31.16.25，172.31.32.201，172.31.48.11，172.31.64.99，172.31.80.150，172.31.96.88，172.31.100.123，172.31.128.45，172.31.160.10，172.31.200.200，172.31.240.5，172.31.254.180）环境；
- 2) 通过 SSH V13 分别输入“bash megatron.sh 39B 16”和“bash overlap.sh 39B 16”命令，分别在三维并行“计算-通信同步”调度算法模式和三维并行“基线 Megatron-LM”模式下执行 105 步的 39B 参数量 GPT-3 模型训练；

3) 执行完毕后, 查看日志并记录在三维并行“计算-通信同步”调度算法模式下和三维并行“基线 Megatron-LM”模式下模型训练吞吐量;

4) 依据计算公式计算出模型训练吞吐量加速比。

(4) 测试结果

测试项	测试结果
三维并行“计算-通信同步”调度算法模式模型训练吞吐量 (tokens/s)	19876.4
三维并行“基线 Megatron-LM”模式下的模型训练吞吐量 (tokens/s)	14968.1
模型训练吞吐量加速比 (%)	32.79

经检测, 在本次 16 台英伟达服务器 (GPU: 8 卡英伟达 2080 Ti, IP 地址: 172.31.43.176, 172.31.43.10, 172.31.0.55, 172.31.10.100, 172.31.16.25, 172.31.32.201, 172.31.48.11, 172.31.64.99, 172.31.80.150, 172.31.96.88, 172.31.100.123, 172.31.128.45, 172.31.160.10, 172.31.200.200, 172.31.240.5, 172.31.254.180) 测试环境中, 通过 SSH V13 输入命令, 在三维并行“计算-通信同步”调度算法模式下、三维并行“基线 Megatron-LM”模式下执行 39B 参数量 GPT-3 模型训练, 三维并行“计算-通信同步”调度算法模式对比三维并行“基线 Megatron-LM”模式下的模型训练吞吐量提升百分比为 32.79%, 模型训练吞吐量加速比超过 30%, 满足测试项“三维并行‘计算-通信同步’调度算法模式对比三维并行‘基线 Megatron-LM’模式下的模型训练吞吐量提升百分比达到或超过 30%”。

4.2.5. 昇腾平台的适配性与性能测试

(1) 性能效率要求

在三维并行“计算-通信同步”调度算法模式下比三维并行“基线 Megatron-LM”模

式下模型训练吞吐量提升比达到或超过 20%，在三维并行“计算-通信同步”调度算法模式下 loss 值曲线下降，则模型正常收敛。

(2) 测试设计

在 72GPU 规模下，通过 SSH V13 输入命令，分别在三维并行“计算-通信同步”调度算法模式下、三维并行“基线 Megatron-LM”模式下执行 8B 参数量 InternVL 3 模型训练，查看日志输出的模型训练吞吐量，计算出模型训练吞吐量提升百分比，计算结果四舍五入取 2 位小数。

计算公式如下：

模型训练吞吐量提升百分比 = (三维并行“计算-通信同步”调度算法模式模型训练吞吐量 - 三维并行“基线 Megatron-LM”模式模型训练吞吐量) ÷ 三维并行“基线 Megatron-LM”模式 × 100%，依据计算公式计算出模型训练吞吐量提升百分比。

(3) 测试步骤

- 1) 部署 9 台昇腾服务器 (GPU: 8 卡昇腾 910B, IP 地址: 10.140.213.1, 10.140.213.15, 10.140.213.19, 10.140.213.20, 10.140.213.43, 10.140.213.48, 10.140.213.50, 10.140.213.51, 10.140.213.59) 环境;
- 2) 通过 SSH V13 分别输入 “bash train_internvl_megatron.sh 9” 和 “bash train_internvl_overlap.sh 9” 命令，分别在三维并行“计算-通信同步”调度算法模式和三维并行“基线 Megatron-LM”模式下执行 1000 步长的 8B 参数量 InternVL 3 模型训练;
- 3) 执行完毕后，生成图并查看在三维并行“计算-通信同步”调度算法模式下的 loss 值曲线下降;
- 4) 执行完毕后，查看日志并记录在三维并行“计算-通信同步”调度算法模式下和三维并行“基线 Megatron-LM”模式下模型训练吞吐量;
- 5) 依据计算公式计算出模型训练吞吐量加速比。

(4) 测试结果

测试项	测试结果
三维并行“计算-通信同步”调度算法模式模型训练吞吐量 (tokens/s)	3217.9
三维并行“基线 Megatron-LM”模式模型训练吞吐量 (tokens/s)	2622.2
模型训练吞吐量提升百分比 (%)	22.72

经检测，在本次 9 台昇腾服务器（GPU：8 卡昇腾 910B，IP 地址：10.140.213.1，10.140.213.15，10.140.213.19，10.140.213.20，10.140.213.43，10.140.213.48，10.140.213.50，10.140.213.51，10.140.213.59）环境中，通过 SSH V13 输入命令，在三维并行“计算-通信同步”调度算法模式下、三维并行“基线 Megatron-LM”模式下执行 8B 参数数量 InternVL 3 模型训练，三维并行“计算-通信同步”调度算法模式对比三维并行“基线 Megatron-LM”模式下的模型训练吞吐量提升比为 22.72%，模型训练吞吐量提升比超过 20%，满足测试项“在三维并行‘计算-通信同步’调度算法模式下比三维并行‘基线 Megatron-LM’模式下模型训练吞吐量提升比达到或超过 20%，生成图并查看在三维并行‘计算-通信同步’调度算法模式下 loss 值曲线下降，模型正常收敛”。

4.2.6. “超网-子网”搜索空间的四维并行训练系统测试

(1) 性能效率要求

- ①关键算子的算力利用率达到或超过 90%；
- ②1 小时内遍历的子网数量达到或超过 14,000 个。

(2) 测试设计

在 4GPU 规模下，通过 SSH V13 输入命令，启动并执行“超网-子网”并行搜索与训练任务，查看日志输出的算力利用率、子网数量。

(3) 测试步骤