

应用示范证明

项目名称	大模型四维并行分布式训练支撑系统		项目编号	2022ZD0160200
课题名称	支持高动态模型的高性能、高扩展四维并行训练系统		课题编号	2022ZD0160201
应用示范单位	单位名称	中国移动通信集团河南有限公司郑州分公司		
	单位地址	河南省郑州市金水区北环路 11 号		
应用落地起始时间	2024 年 3 月 1 日			
应用示范的具体情况 & 经济社会效益: 由香港大学研发的面向国产昇腾（Ascend 910B）平台的大模型高性能训练与推理并行加速方法 Fold3D 系列成果，涵盖 FoldPipelineTransformer（源自[Fold3D TPDS 2023] 论文）及其子技术 FoldMoE，深度融合数据并行、张量并行、流水线并行的三维并行策略，首创 AFAPAB（又称 AIAO）高并行调度技术，结合算子融合、KV Cache 复用、通信-计算重叠等单卡级优化手段，在不改变硬件配置和现有集群拓扑的前提下，显著提升了昇腾 910B 单卡的算力利用率与吞吐能力。在我司昇腾 910B 现网集群的实际部署与验证中，上述方法作为国产自主研发的加速方案，有效替代了对国外同类并行框架（如英伟达 Megatron）的依赖，具备完全的自主可控性，并且据我司了解，是适配昇腾加速卡的 MindSpore 开源软件库中唯一的国产三维并行方案。 该 FoldPipelineTransformer 应用成功支持了我司郑州节点 2048 卡昇腾 910B 现网集群（由 2 个 1024 卡子集群构成）上 Transformer 大模型的高性能稳定训练 90 天，每张训练吞吐高达 22.8K tokens/min，相比 Megatron 的 17.4K tokens/min 提升约 30.80%。FoldMoE 部署于我司郑州节点昇腾 910B 现网集群，稳定支撑面向终端用户的大模型推理与微调服务，单卡推理吞吐由基线 52.0K tokens/min 提升至 57.2K tokens/min，经济效益显著。 作为中原地区大模型算力中心节点，郑州节点全年承载约 60 个 Transformer 大模型的推理与微调业务，服务省内政务、金融、教育、工业质检等多行业客户。节点每日平均活跃 910B 卡约 1800 张（面向省内客户的内部结算租金约 90 元/卡·日，低于市场公允价，体现运营商算力的普惠性），日均算力出租收入约 16.2 万元。依托 Fold3D 系列成果带来的吞吐加速增益，现有 1800 张日活卡承载了原部署方案下需约 1980 张卡的业务量，等效新增约 180 张昇腾 910B 卡的算力供给，可承载更多客户任务，直接实现了算力服务能力与资源利用效率的双重提升；按内部结算价折算，为省内客户节省算力费用约 1.6 万元/日，降低了单位 token 的算力成本，助力我司在承接政企与公众大模型业务时保持成本竞争力。在国产高端算力资源紧缺的背景下，以同等硬件规模承载了更多的推理与微调业务，有效缓解了区域算力供需矛盾，使有限的算力资源能够惠及更广泛的行业与社会领域，产生了良好的经济效益与社会效益。 本证明仅用于学术类奖项申报。特此证明。 中国移动通信集团河南有限公司郑州分公司（盖章） 云业务中心 2026 年 7 月 16 日				